Taller 1. Informe de Análisis de Componentes Principales

Análisis Multivariado

Maestría en Inteligencia Artificial y Ciencia de Datos

Tema: Análisis de Componentes Principales aplicado a calidad del agua del Río Cauca

Integrantes

JHONATAN ANDRES TAPIA CORDOBA

JORGE ANDRES JARAMILLO NEME

LUIS FERNANDO MEZA RAMREZ

Fuente de datos: Base de datos/Calidad_del_agua_del_Rio_Cauca_20260419.csv

Fecha de entrega: Mayo 2 de 2026

Índice

Resumen ejecutivo **2**

1. Introducción **2**

2. Datos y preparación metodológica **2**

3. Estadísticas descriptivas, correlaciones y gráficos **3**

4. Análisis de Componentes Principales **6**

5. Nube de individuos **7**

6. Círculo de correlaciones **8**

7. Biplot y datos atípicos **9**

8. Síntesis con contribuciones y cosenos cuadrados **10**

9. Construcción de índice **11**

10. Hallazgos principales **12**

11. Conclusiones **13**

Resumen ejecutivo

El Análisis de Componentes Principales aplicado a siete variables físico-químicas del Río Cauca permitió resumir la información en tres componentes con valor propio mayor que 1. Estas tres dimensiones explican el **77,15 %** de la variabilidad total. La primera dimensión representa un gradiente de carga contaminante y particulada, dominado por sólidos suspendidos, turbiedad, DBO, DQO y fósforo total. La segunda dimensión contrasta oxígeno disuelto y conductividad eléctrica, por lo que aporta una lectura ambiental complementaria.

Los resultados muestran que sí es posible construir un índice, pero debe interpretarse como **índice parcial de carga contaminante/particulada**, no como índice global de calidad del agua. También se identificaron observaciones extremas en años y estaciones específicas, entre ellas JUANCHITO 1993 y varias estaciones en 2010, que deben revisarse como posibles eventos ambientales particulares y no eliminarse automáticamente.

1. Introducción

El presente informe desarrolla una aplicación técnica de Análisis de Componentes Principales (ACP) sobre una base de datos real de calidad del agua del Río Cauca. El objetivo es resumir la estructura multivariada de un conjunto de variables físico-químicas, identificar relaciones entre indicadores ambientales, observar patrones entre estaciones de monitoreo y evaluar si es posible construir un índice sintético a partir de los componentes principales.

El ACP es pertinente para este caso porque las variables de calidad del agua se encuentran medidas en distintas unidades y pueden presentar correlaciones entre sí. La técnica permite transformar el conjunto original de variables en nuevas dimensiones no correlacionadas, denominadas componentes principales, que concentran la mayor parte posible de la variabilidad total.

2. Datos y preparación metodológica

La base original contiene **2368 registros y 56 variables**. Como primer paso, se realizó una limpieza de nombres de columnas, conversión de variables numéricas y normalización de formatos atípicos, incluyendo separador decimal con coma y notación científica escrita como `*10E`.

Se construyó el identificador `anio_estacion`, combinando el año de muestreo con la estación. Esta decisión permite interpretar cada individuo como una observación espacio-temporal, evitando mezclar mediciones de diferentes años en una misma estación.

Durante la auditoría de valores faltantes se identificaron variables con ausencia total de información, por ejemplo hierro disuelto, manganeso disuelto, sodio disuelto, potasio disuelto, cobre disuelto, zinc disuelto, cianuros, fluoruros, sulfuros y sílice. Por esta razón, el ACP se concentró en variables con disponibilidad y relevancia ambiental.

Cuadro 1: Variables activas seleccionadas

Variable	**Interpretación ambiental**
Turbiedad	Material particulado y transparencia del agua
Sólidos suspendidos totales	Carga de sedimentos y partículas
Demanda bioquímica de oxígeno (DBO)	Materia orgánica biodegradable
Demanda química de oxígeno (DQO)	Carga orgánica y química oxidable
Oxígeno disuelto	Condición de oxigenación del agua
Conductividad eléctrica	Presencia de sales e iones disueltos
Fósforo total	Nutrientes asociados a eutrofización

Todas las variables seleccionadas presentaron asimetría positiva severa, por lo cual se aplicó transformación `log1p`. Posteriormente se eliminaron registros incompletos mediante eliminación por caso completo. La matriz final del ACP quedó conformada por **1475 observaciones**, equivalentes al **62,29 %** de la base de análisis.

3. Estadísticas descriptivas, correlaciones y gráficos

La exploración inicial muestra alta dispersión en las variables seleccionadas. Los coeficientes de variación fueron elevados, especialmente en DBO, fósforo total y oxígeno disuelto. Esto evidencia heterogeneidad importante en la calidad del agua observada a través del tiempo y entre estaciones. Además, todas las variables presentaron asimetría positiva mayor que 2, por lo cual se justificó la transformación logarítmica antes del ACP.

Cuadro 2: Estadísticas descriptivas

Variable	**n**	**Media**	**Desv. est.**	**Min**	**Max**	**Asimetría**	**CV %**
Turbiedad	2185	128,00	169,00	1,00	1900,00	2,90	132,00
Sólidos suspendidos totales	2297	161,00	199,00	1,20	2112,00	3,13	124,00
DBO	2203	5,94	19,10	0,10	427,00	12,20	322,00
DQO	2134	30,20	37,90	1,46	706,00	6,90	125,00
Oxígeno disuelto	2289	4,70	9,39	0,00	216,00	14,70	200,00
Conductividad eléctrica	2305	123,00	106,00	0,00	4259,00	28,10	85,50
Fósforo total	1850	0,30	0,88	0,00	14,20	9,64	293,00

El diagnóstico de valores extremos mediante el criterio de Tukey mostró presencia de atípicos univariados en todas las variables, especialmente en turbiedad, DQO, sólidos suspendidos y DBO. Por esta razón, dichos valores no se eliminaron de forma automática; se redujo su peso relativo mediante `log1p` y se evaluaron posteriormente en el plano factorial.

Cuadro 3: Diagnóstico de valores atípicos univariados

Variable	**Atípicos**	**Acción aplicada**
Turbiedad	216	Transformación log1p
Sólidos suspendidos totales	159	Transformación log1p
DBO	152	Transformación log1p
DQO	201	Transformación log1p
Oxígeno disuelto	35	Transformación log1p
Conductividad eléctrica	15	Transformación log1p
Fósforo total	95	Transformación log1p

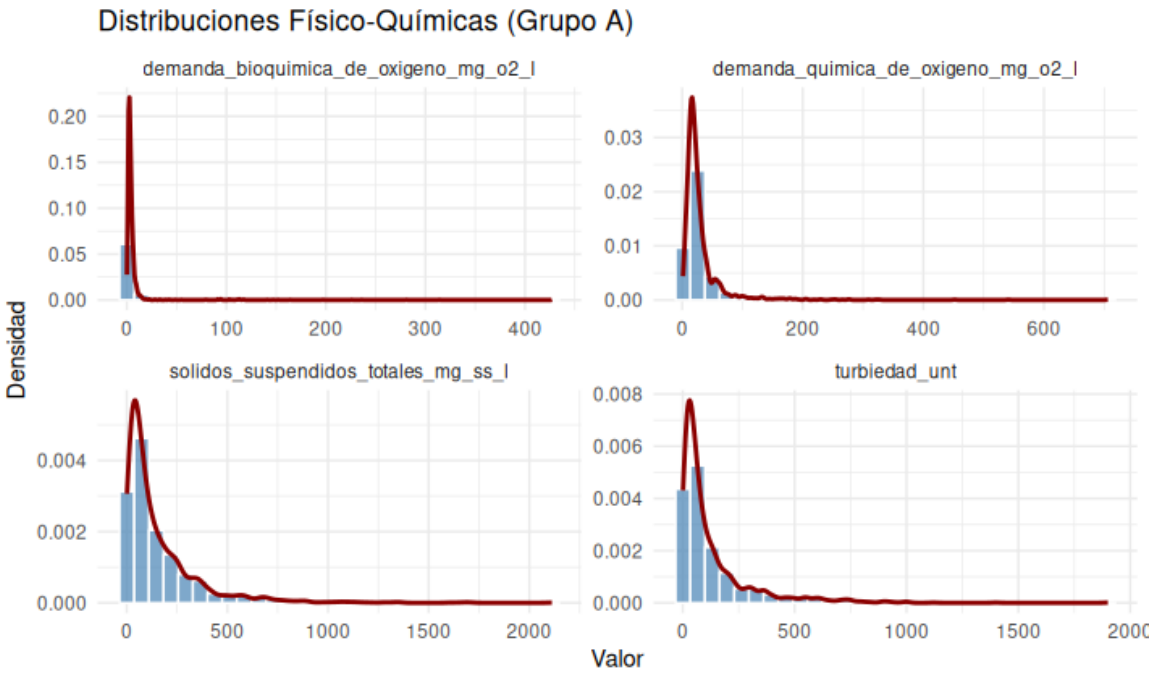

Figura 1: Distribuciones físico-químicas, grupo A

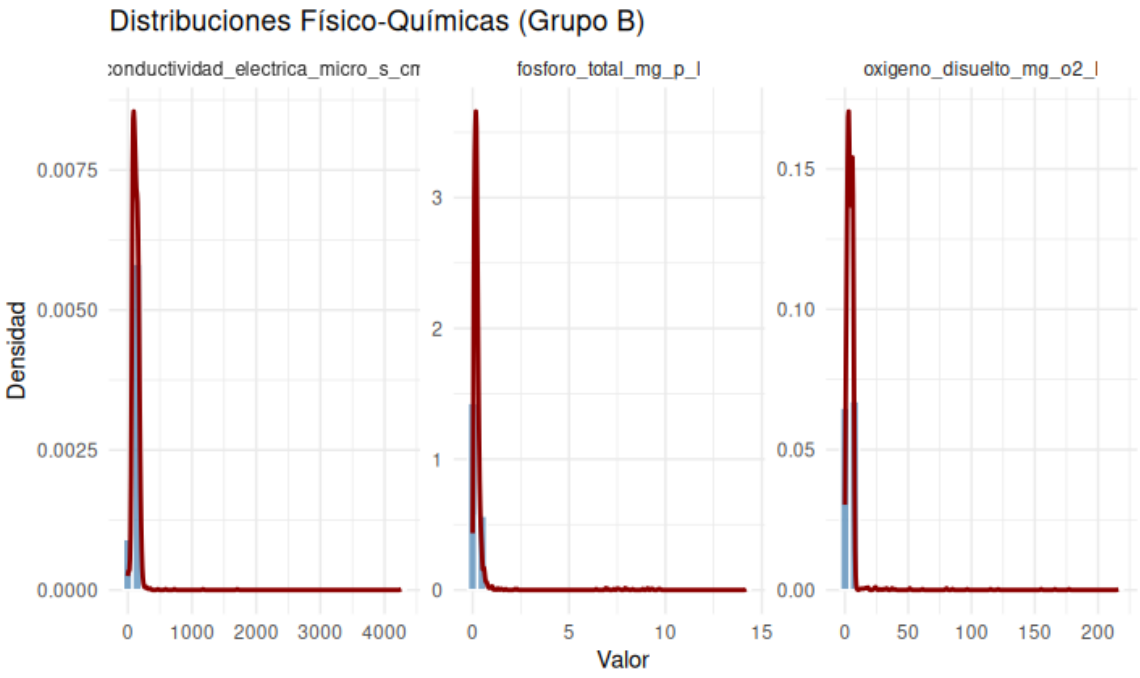

Figura 2: Distribuciones físico-químicas, grupo B

La matriz de correlación transformada indica relaciones relevantes. La asociación más fuerte se presenta entre **turbiedad y sólidos suspendidos totales** (r = 0,80), lo cual es coherente con la interpretación ambiental de carga particulada. También se observa relación entre **DBO y fósforo total** (r = 0,60), que puede asociarse a procesos de contaminación orgánica y aporte de nutrientes. Por otra parte, el oxígeno disuelto se relaciona negativamente con la conductividad eléctrica (r = -0,54) y con DQO (r = -0,27), sugiriendo una dimensión diferente vinculada con condiciones de oxigenación frente a carga iónica o química.

Cuadro 4: Matriz de correlación sobre variables transformadas

Variable	**Turbiedad**	**SST**	**DBO**	**DQO**	**OD**	**Conductividad**	**Fósforo**
Turbiedad	1,00	0,80	0,09	0,23	0,15	-0,06	0,10
SST	0,80	1,00	0,21	0,38	0,10	0,07	0,23
DBO	0,09	0,21	1,00	0,15	-0,20	0,23	0,60
DQO	0,23	0,38	0,15	1,00	-0,27	0,24	-0,01
OD	0,15	0,10	-0,20	-0,27	1,00	-0,54	0,16
Conductividad	-0,06	0,07	0,23	0,24	-0,54	1,00	-0,01
Fósforo	0,10	0,23	0,60	-0,01	0,16	-0,01	1,00

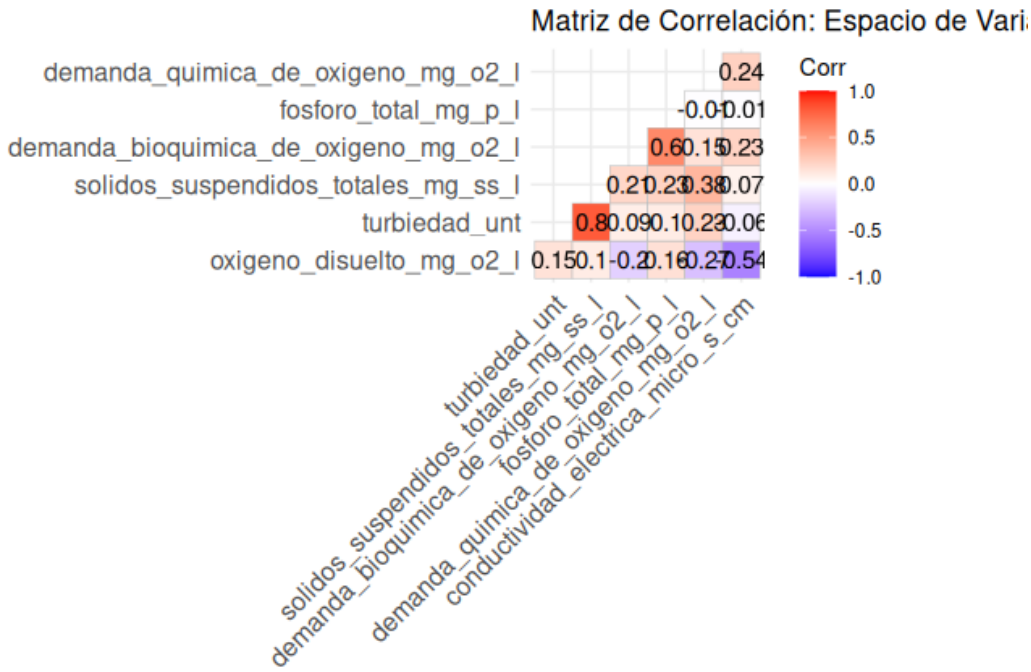

Figura 3: Matriz de correlación

4. Análisis de Componentes Principales

El ACP se realizó sobre variables transformadas y estandarizadas. La estandarización es necesaria porque las variables están expresadas en unidades diferentes: UNT, mg/L y microS/cm. Las variables `anio_estacion` y `estaciones` se trataron como cualitativas suplementarias para apoyar la interpretación, sin influir en la construcción de los ejes factoriales.

Cuadro 5: Valores propios e inercia explicada

Componente	Valor propio	% varianza	% acumulado
Dim 1	2,210	31,568	31,568
Dim 2	1,780	25,431	56,999
Dim 3	1,410	20,148	77,147
Dim 4	0,670	9,565	86,712
Dim 5	0,466	6,659	93,371
Dim 6	0,296	4,224	97,594
Dim 7	0,168	2,406	100,000

Con el criterio de Kaiser, se retienen **tres componentes** con valores propios mayores que 1. Estos tres componentes explican el **77,15 %** de la variabilidad total. El plano factorial

1-2 explica **57,00 %**, porcentaje suficiente para una primera lectura gráfica, aunque no agota completamente la estructura multivariada.

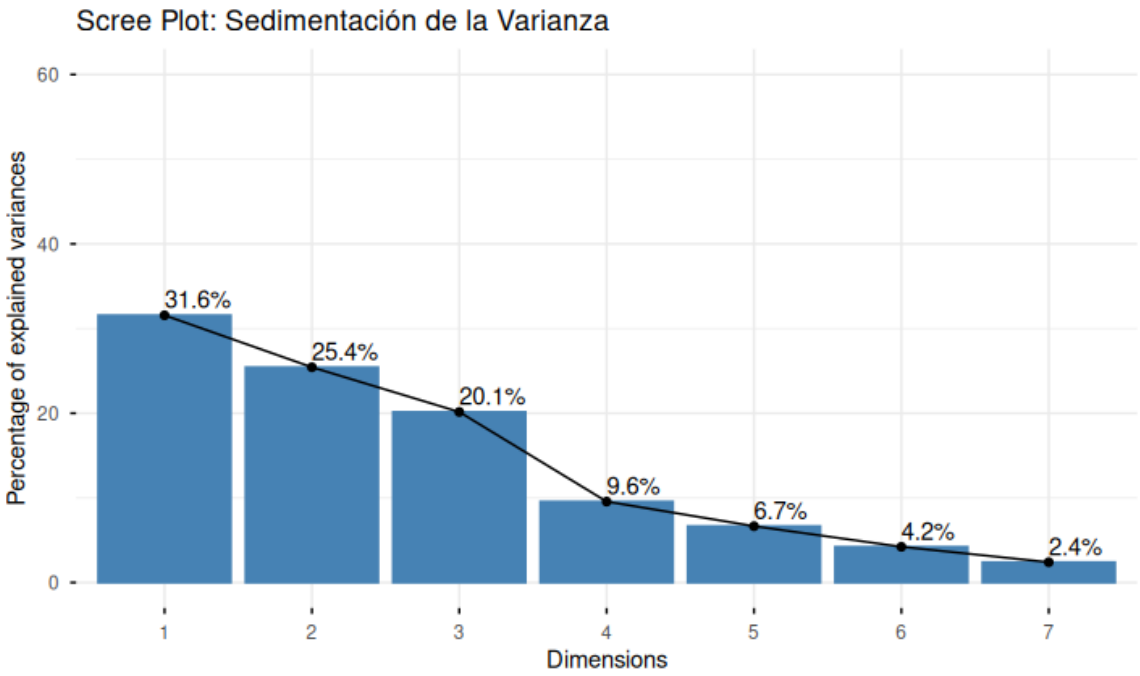

Figura 4: Sedimentación de la varianza

5. Nube de individuos

La nube de individuos permite observar cómo se distribuyen las observaciones espacio-temporales en el plano factorial formado por las dimensiones 1 y 2. Los puntos más alejados del origen representan observaciones con perfiles físico-químicos más diferenciados respecto al comportamiento promedio.

Cuadro 6: Individuos mejor representados en el plano 1-2

Individuo	**Dim 1**	**Dim 2**	**Cos2 plano**
2013_ANTES SUAREZ	-2,145	1,375	0,992
2011_PASO DEL COMERCIO	1,929	1,695	0,985
1997_PUENTE HORMIGUERO	-2,190	1,341	0,978
1998_ANTES RIO OVEJAS	-4,093	-0,461	0,976
2000_PASO DE LA BOLSA	-1,714	1,469	0,972

Estos casos tienen una representación confiable en el plano 1-2, por lo cual su posición gráfica puede interpretarse con mayor seguridad.

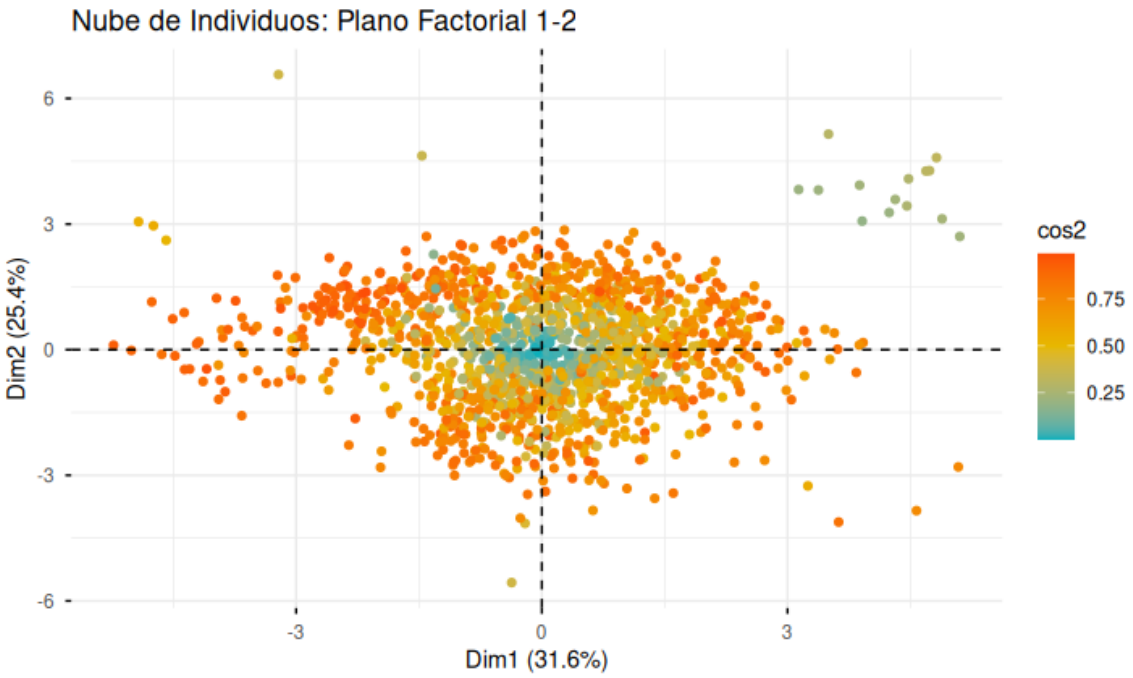

Figura 5: Nube de individuos

6. Círculo de correlaciones

El círculo de correlaciones muestra la relación entre las variables originales y los componentes principales. En la Dim 1 predominan variables asociadas a carga contaminante y particulada: sólidos suspendidos totales, turbiedad, DBO, DQO y fósforo total. En la Dim 2 se destacan principalmente oxígeno disuelto y conductividad eléctrica, pero con signos opuestos.

Cuadro 7: Interpretación de los ejes factoriales

Dimensión	**Variables principales**	**Interpretación**
Dim 1	Sólidos suspendidos, turbiedad, DBO, DQO, fósforo	Gradiente de carga contaminante, o
Dim 2	Oxígeno disuelto (+), conductividad eléctrica (-)	Contraste entre oxigenación e influe

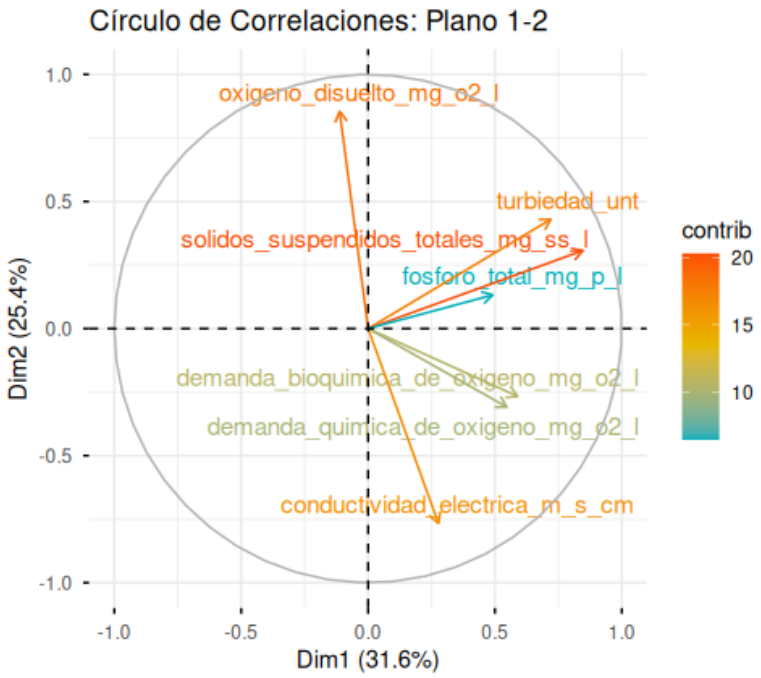

Figura 6: Círculo de correlaciones

7. Biplot y datos atípicos

El biplot integra individuos y variables en una misma representación. Las observaciones ubicadas en la dirección de una variable tienden a presentar valores relativamente altos en esa variable. En el lado positivo de la Dim 1 se ubican observaciones asociadas a mayor carga particulada y orgánica; en la Dim 2 se observa el contraste entre oxígeno disuelto y conductividad eléctrica.

Para identificar posibles datos atípicos se utilizó la distancia al origen en el plano factorial. Los diez casos más alejados fueron:

Cuadro 8: Posibles atípicos factoriales

Individuo	**Estación**	**Dim 1**	**Dim 2**	**Distancia**	**Cos2 plano**
1993_JUANCHITO	JUANCHITO	-3,216	6,571	53,519	0,393
2010_MEDIACANOA	MEDIACANOA	4,819	4,587	44,265	0,329
2010_PASO DEL COMERCIO	PASO DEL COMERCIO	4,734	4,277	40,700	0,317
2010_PUERTO ISAACS	PUERTO ISAACS	4,691	4,267	40,219	0,313
2010_JUANCHITO	JUANCHITO	3,500	5,149	38,761	0,297
2010_YOTOCO	YOTOCO	4,478	4,081	36,700	0,274
1990_ANTES INTERCEPTOR SUR	ANTES INTERCEPTOR SUR	4,575	-3,844	35,708	0,740
1994_PASO DEL COMERCIO	PASO DEL COMERCIO	5,086	-2,800	33,702	0,753
2010_ANACARO	ANACARO	4,887	3,125	33,653	0,240
1992_ANTES RIO TIMBA	ANTES RIO TIMBA	-4,925	3,058	33,600	0,554

Estos registros no deben eliminarse automáticamente, ya que pueden corresponder a eventos reales de contaminación, condiciones hidrológicas particulares o cambios temporales relevantes. Deben interpretarse como observaciones extremas desde el punto de vista factorial.

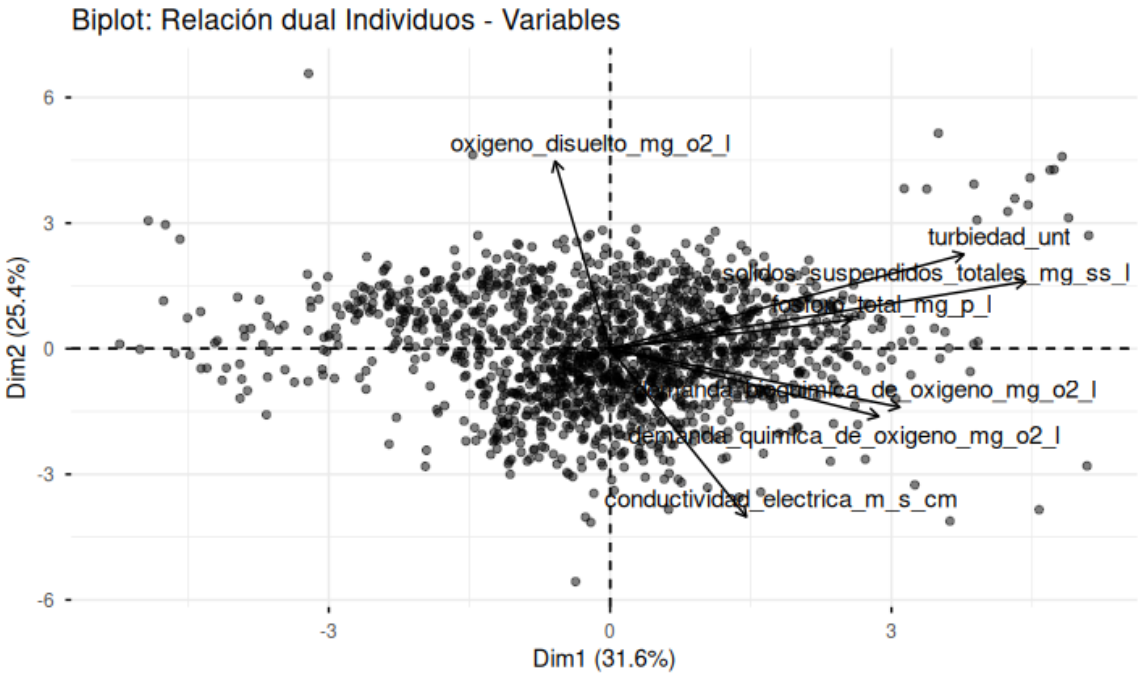

Figura 7: Biplot: relación dual individuos-variables

8. Síntesis con contribuciones y cosenos cuadrados

El aporte promedio esperado por variable en cada dimensión es $100/7 =$ **14,29 %**. En la Dim 1, las mayores contribuciones corresponden a sólidos suspendidos totales, turbiedad y DBO. En conjunto, estas variables sostienen la interpretación de la Dim 1 como un gradiente de carga contaminante y particulada.

Cuadro 9: Contribuciones y cosenos cuadrados en la Dimensión 1

Variable	**Coord. Dim 1**	**Contrib. Dim 1**	**Cos2 Dim 1**
Sólidos suspendidos totales	0,846	32,358	0,715
Turbiedad	0,720	23,453	0,518
DBO	0,589	15,712	0,347
DQO	0,547	13,519	0,299
Fósforo total	0,491	10,913	0,241
Conductividad eléctrica	0,277	3,477	0,077
Oxígeno disuelto	-0,112	0,568	0,013

En la Dim 2, las variables dominantes son oxígeno disuelto y conductividad eléctrica. La oposición de signos sugiere que este componente expresa una condición ambiental distinta a la Dim 1.

Cuadro 10: Contribuciones y cosenos cuadrados en la Dimensión 2

Variable	**Coord. Dim 2**	**Contrib. Dim 2**	**Cos2 Dim 2**
Oxígeno disuelto	0,854	41,015	0,730
Conductividad eléctrica	-0,766	32,983	0,587
Turbiedad	0,430	10,381	0,185
DQO	-0,309	5,355	0,095
Sólidos suspendidos totales	0,307	5,288	0,094
DBO	-0,267	3,992	0,071
Fósforo total	0,133	0,986	0,018

En síntesis, los cosenos cuadrados indican que los sólidos suspendidos y la turbiedad están bien representados por la Dim 1, mientras que oxígeno disuelto y conductividad eléctrica están mejor representados por la Dim 2. Esta separación respalda que el fenómeno no es unidimensional: existe un eje de carga particulada/orgánica y otro eje de condición físico-química asociada a oxigenación y conductividad.

9. Construcción de índice

La Dim 1 explica **31,57 %** de la varianza total y presenta cargas positivas en 6 de las 7 variables activas. Además, las variables con mayor contribución en esta dimensión tienen una interpretación ambiental coherente: sólidos suspendidos, turbiedad, DBO, DQO y fósforo. Esta coherencia permite construir un indicador ordenado por la posición de los individuos sobre la Dim 1.

Por lo anterior, **sí es posible construir un índice parcial basado en la Dim 1**, pero no se recomienda interpretarlo como un índice global de calidad del agua. La razón es que la Dim 2 contiene información ambiental importante, especialmente sobre oxígeno disuelto y conductividad eléctrica, que no queda completamente representada por la Dim 1. En consecuencia, el índice se interpreta como **índice parcial de carga contaminante/particulada**: valores altos indican mayor carga relativa, no necesariamente peor calidad integral en todos los criterios ambientales.

El índice construido se normalizó en escala 0-100 a partir de la coordenada factorial de cada individuo en la Dim 1:

$$\text{Indice_PC1_0_100} = 100 \times \frac{PC1 - \text{mín}(PC1)}{\text{máx}(PC1) - \text{mín}(PC1)}$$

Valores cercanos a 100 indican mayor carga contaminante/particulada según la estructura capturada por la Dim 1.

Cuadro 11: Mayores valores individuales del índice parcial

Individuo	**Estación**	**PC1**	**Índice**
2010_LA VICTORIA	LA VICTORIA	5,104	100,000
1994_PASO DEL COMERCIO	PASO DEL COMERCIO	5,086	99,825
2010_ANACARO	ANACARO	4,887	97,906
2010_MEDIACANOA	MEDIACANOA	4,819	97,245
2010_PASO DEL COMERCIO	PASO DEL COMERCIO	4,734	96,422
2010_PUERTO ISAACS	PUERTO ISAACS	4,691	96,009
1990_ANTES INTERCEPTOR SUR	ANTES INTERCEPTOR SUR	4,575	94,881
2010_YOTOCO	YOTOCO	4,478	93,942
2010_PUENTE LA VIRGINIA	PUENTE LA VIRGINIA	4,458	93,750
2010_PASO DE LA TORRE	PASO DE LA TORRE	4,315	92,371

Cuadro 12: Estaciones con mayor índice parcial promedio

Estación	**n mediciones**	**Índice promedio**	**Índice máximo**
ANACARO	92	57,6	97,9
PUENTE LA VIRGINIA	89	57,5	93,8
LA VICTORIA	90	57,4	100,0
VIJES	88	56,6	88,2
PUENTE GUAYABAL	92	56,6	88,6
RIOFRIO	90	56,3	91,7
YOTOCO	87	56,0	93,9
MEDIACANOA	100	55,9	97,2
PASO DE LA TORRE	87	53,9	92,4
PASO DEL COMERCIO	96	53,4	99,8

10. Hallazgos principales

1. La base de datos presenta alta heterogeneidad y asimetría positiva en las variables físico-químicas analizadas, lo que justificó el uso de transformación logarítmica.

2. La correlación más fuerte se encontró entre turbiedad y sólidos suspendidos totales, evidenciando una dimensión clara de carga particulada.

3. El ACP retuvo tres componentes según el criterio de Kaiser, explicando el 77,15 % de la variabilidad total.

4. El plano Dim 1-Dim 2 explicó 57,00 % de la variabilidad, suficiente para interpretar patrones generales de individuos y variables.

5. La Dim 1 representa principalmente carga contaminante/particulada, mientras que la Dim 2 refleja un contraste entre oxígeno disuelto y conductividad eléctrica.

6. Se identificaron observaciones extremas, especialmente en estaciones y años como JUANCHITO 1993, MEDIACANOA 2010, PASO DEL COMERCIO 2010 y PUERTO ISAACS 2010.

7. Es posible construir un índice parcial de carga contaminante basado en PC1, pero no un índice global de calidad del agua, porque PC2 contiene información ambiental relevante no resumida por PC1.

8. Las estaciones con mayores promedios del índice parcial fueron ANACARO, PUENTE LA VIRGINIA, LA VICTORIA, VIJES y PUENTE GUAYABAL.

11. Conclusiones

El Análisis de Componentes Principales permitió resumir adecuadamente la estructura multivariada de las variables físico-químicas del Río Cauca. La primera dimensión sintetiza un gradiente de contaminación asociado a sólidos suspendidos, turbiedad, DBO, DQO y fósforo total. La segunda dimensión complementa la interpretación al representar principalmente el contraste entre oxígeno disuelto y conductividad eléctrica.

Los resultados muestran que la calidad del agua no puede describirse de manera completa con un único eje factorial. Sin embargo, la Dim 1 ofrece una base coherente para construir un índice parcial de carga contaminante/particulada, útil para ordenar observaciones y estaciones según su perfil relativo. Este índice debe interpretarse con cautela y acompañarse de la lectura de la Dim 2 para no perder información ambiental importante.

En términos aplicados, el ACP permitió identificar variables dominantes, estaciones con mayor carga relativa y observaciones extremas que podrían ser objeto de revisión ambiental o análisis complementario.