Análisis de Componentes Principales aplicado a calidad del agua del Río Cauca

Taller 1. Análisis Multivariado

JHONATAN ANDRES TAPIA CORDOBA
JORGE ANDRES JARAMILLO NEME
LUIS FERNANDO MEZA RAMREZ

Maestría en Inteligencia Artificial y Ciencia de Datos

Mayo 2 de 2026

Objetivo de la sustentación

- Aplicar ACP sobre variables físico-químicas de calidad del agua del Río Cauca.
- Resumir la información multivariada en dimensiones interpretables.
- Interpretar los principales gradientes ambientales.
- Identificar observaciones atípicas.
- Evaluar si es posible construir un índice.

Importante: el ACP permite pasar de varias variables correlacionadas a pocas dimensiones interpretables.

Datos y preparación

- Base original: **2368 registros y 56 variables**.
- Se limpiaron nombres de columnas y formatos numéricos.
- Se corrigieron valores con coma decimal y notación científica tipo `*10E`.
- Se construyó el identificador `anio_estacion`.
- Las variables con 100 % de valores faltantes fueron descartadas.

Cada individuo se interpreta como una observación espacio-temporal: año más estación de monitoreo.

Variables activas y tratamiento

- Turbiedad.
- Sólidos suspendidos totales.
- DBO.
- DQO.
- Oxígeno disuelto.
- Conductividad eléctrica.
- Fósforo total.

- Todas presentaron asimetría positiva severa.
- Se aplicó transformación `log1p`.
- Luego se estandarizaron por estar en unidades diferentes.
- Matriz final del ACP: **1475 observaciones**.
- Conservación: **62,29 %**.

Estadísticas descriptivas

- La exploración descriptiva mostró alta heterogeneidad.
- Los coeficientes de variación fueron altos, especialmente en DBO, fósforo total y oxígeno disuelto.
- Esto justificó la transformación logarítmica antes del ACP.

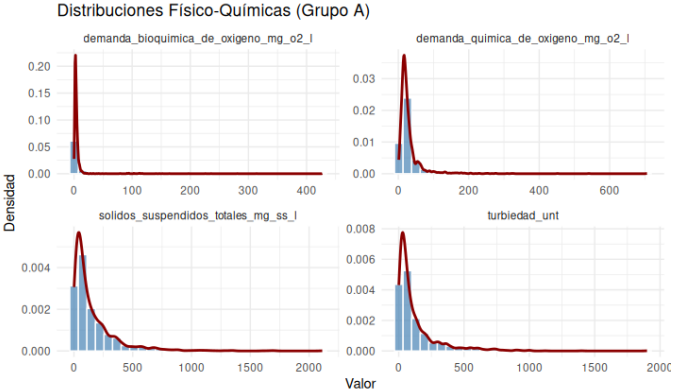

Distribuciones físico-químicas

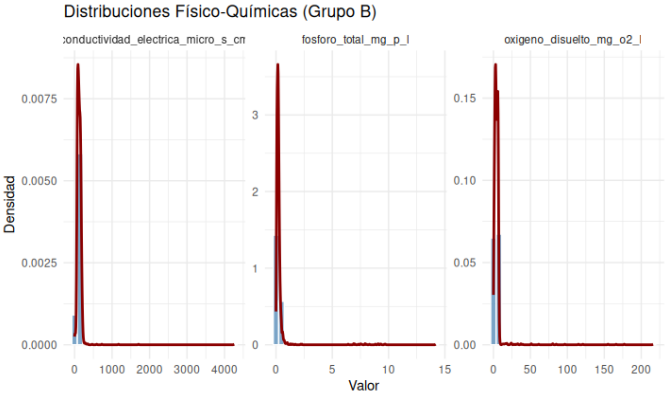

Las distribuciones muestran asimetrías positivas y valores extremos, por lo que se usó `log1p`.

Matriz de correlación

- Turbiedad y sólidos suspendidos totales: **r = 0,80**.
- DBO y fósforo total: **r = 0,60**.
- Oxígeno disuelto y conductividad eléctrica: **r = -0,54**.

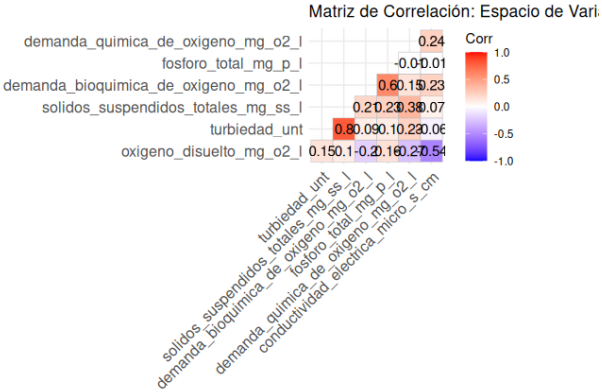

Varianza explicada por el ACP

- Criterio de Kaiser: se retienen **tres componentes**.
- Dim 1: **31,57 %**.
- Dim 2: **25,43 %**.
- Dim 3: **20,15 %**.
- Acumulado en tres dimensiones: **77,15 %**.
- Plano 1-2: **57,00 %**.

Sedimentación de varianza

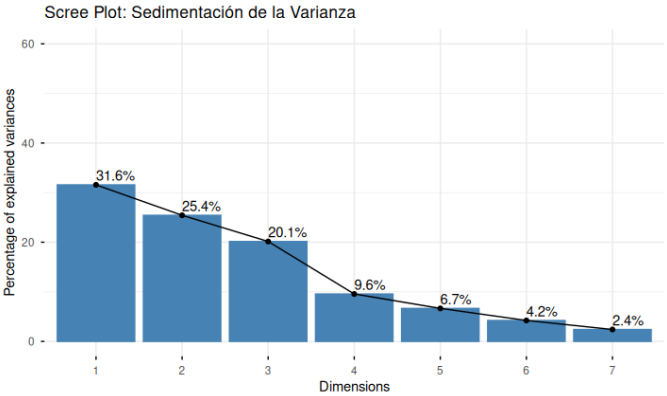

El plano 1-2 es útil para la lectura gráfica, aunque la tercera dimensión conserva información adicional.

Nube de individuos

- Los puntos cercanos al origen tienen perfiles más promedio.
- Los puntos alejados representan perfiles físico-químicos diferenciados.
- Los individuos mejor representados tienen mayor coseno cuadrado en el plano.

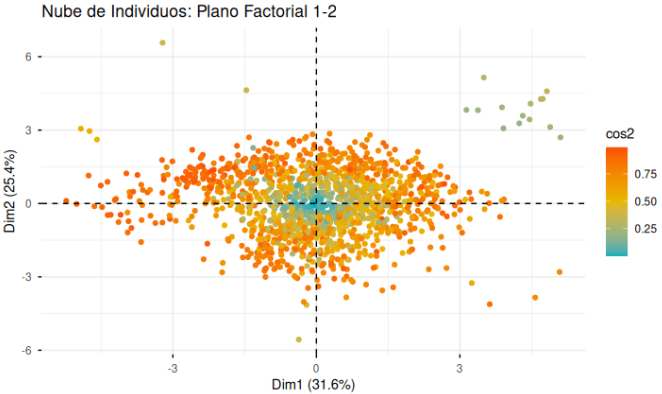

Individuos mejor representados

Individuo	Dim 1	Dim 2	Cos2 plano
2013_ANTES SUAREZ	-2,145	1,375	0,992
2011_PASO DEL COMERCIO	1,929	1,695	0,985
1997_PUENTE HORMIGUERO	-2,190	1,341	0,978
1998_ANTES RIO OVEJAS	-4,093	-0,461	0,976
2000_PASO DE LA BOLSA	-1,714	1,469	0,972

Estos casos tienen representación confiable en el plano factorial 1-2.

Círculo de correlaciones

- **Dim 1:** sólidos suspendidos, turbiedad, DBO, DQO y fósforo total.
- Interpretación: gradiente de carga contaminante, orgánica y particulada.
- **Dim 2:** oxígeno disuelto y conductividad eléctrica en sentidos opuestos.
- Interpretación: contraste entre oxigenación e influencia iónica/conductiva.

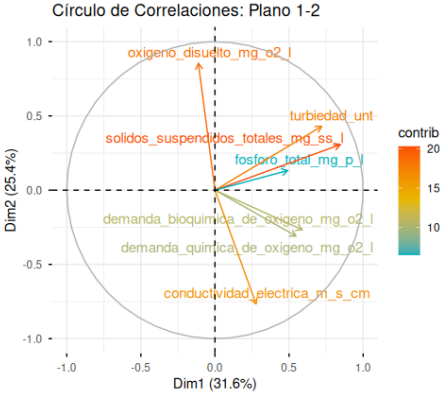

Biplot y datos atípicos

- El biplot integra individuos y variables.
- Las observaciones en dirección de una variable tienden a presentar valores altos en ella.
- Los posibles atípicos se identificaron por distancia al origen en el plano factorial.

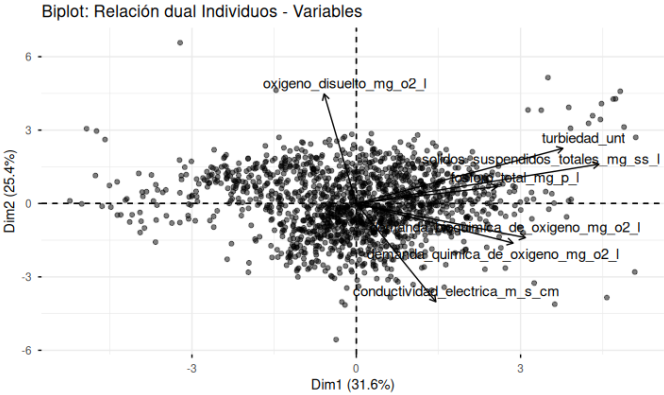

Posibles atípicos factoriales

- 1993_JUANCHITO.
- 2010_MEDIACANOA.
- 2010_PASO DEL COMERCIO.
- 2010_PUERTO ISAACS.
- 2010_JUANCHITO.
- 2010_YOTOCO.

Estos registros no deben eliminarse automáticamente. Pueden representar eventos reales de contaminación, cambios hidrológicos o condiciones ambientales particulares.

Síntesis con contribuciones y cosenos

- Aporte promedio esperado por variable: **14,29 %**.
- En Dim 1 dominan:
  - Sólidos suspendidos totales: **32,36 %**.
  - Turbiedad: **23,45 %**.
  - DBO: **15,71 %**.
- En Dim 2 dominan:
  - Oxígeno disuelto: **41,02 %**.
  - Conductividad eléctrica: **32,98 %**.

Construcción del índice

- Sí es posible construir un índice, pero como **índice parcial**.
- No debe interpretarse como índice global de calidad del agua.
- PC1 explica **31,57 %** y resume carga contaminante/particulada.
- PC2 conserva información importante sobre oxígeno disuelto y conductividad.

$$\text{Indice_PC1_0_100} = 100 \times \frac{PC1 - \text{mín}(PC1)}{\text{máx}(PC1) - \text{mín}(PC1)}$$

Resultados del índice parcial

- Valores cercanos a 100 indican mayor carga contaminante/particulada según PC1.
- Mayores valores individuales:
  - 2010_LA VICTORIA.
  - 1994_PASO DEL COMERCIO.
  - 2010_ANACARO.
  - 2010_MEDIACANOA.
  - 2010_PASO DEL COMERCIO.
- Mayores promedios por estación: ANACARO, PUENTE LA VIRGINIA, LA VICTORIA, VIJES y PUENTE GUAYABAL.

Conclusiones

1. El ACP resumió siete variables físico-químicas en dimensiones interpretables.
2. La Dim 1 representa carga contaminante y particulada.
3. La Dim 2 complementa la lectura mediante el contraste entre oxígeno disuelto y conductividad eléctrica.
4. Se identificaron observaciones extremas potencialmente relevantes.
5. El índice construido debe leerse como índice parcial de carga contaminante.

La calidad del agua del Río Cauca no se resume completamente en un solo eje.

Preguntas probables

¿Por qué log1p? Por asimetría positiva severa y valores extremos.

¿Por qué estandarizar? Porque las variables estaban en unidades distintas.

¿Por qué tres componentes? Porque tres valores propios fueron mayores que 1 y explicaron 77,15 %.

¿Por qué el índice no es global? Porque PC2 contiene información ambiental relevante no resumida por PC1.

¿Qué significa un atípico en ACP? Una observación alejada del centro factorial; no necesariamente un error.