Análisis de Componentes Principales aplicado a calidad del agua del Río Cauca

Taller 1. Análisis Multivariado

JHONATAN ANDRES TAPIA CORDOBA
JORGE ANDRES JARAMILLO NEME
LUIS FERNANDO MEZA RAMREZ

Maestría en Inteligencia Artificial y Ciencia de Datos

Mayo 2 de 2026

Objetivo y alcance

- Aplicar ACP sobre variables físico-químicas de calidad del agua del Río Cauca.
- Resumir la información multivariada en dimensiones interpretables.
- Identificar patrones, observaciones atípicas y posibilidad de construir un índice.

Idea central: la calidad del agua no se resume completamente en una sola variable ni en un solo eje factorial.

Datos y preparación

- Base original: **2368 registros y 56 variables**.
- Limpieza de nombres y formatos numéricos.
- Variables sin información útil fueron descartadas.
- Individuo: combinación `anio_estacion`.
- Variables activas: turbiedad, SST, DBO, DQO, OD, conductividad y fósforo.
- Transformación `log1p` por asimetría positiva severa.
- Estandarización por unidades diferentes.
- Matriz final: **1475 observaciones (62,29 %)**.

Distribuciones de las variables

Las distribuciones muestran asimetría positiva y valores extremos. Por eso se aplicó `log1p` antes del ACP.

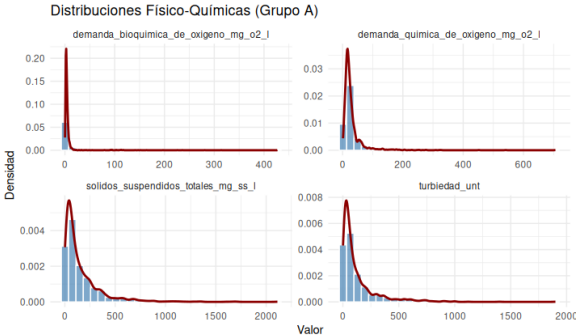

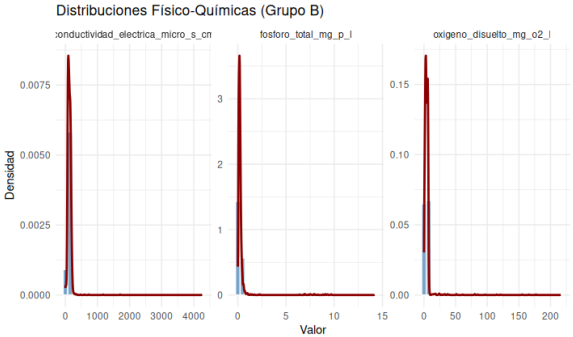

Exploración y correlaciones

- Alta heterogeneidad, especialmente en DBO, fósforo total y oxígeno disuelto.
- Turbiedad y sólidos suspendidos totales: **r = 0,80**.
- DBO y fósforo total: **r = 0,60**.
- Oxígeno disuelto y conductividad eléctrica: **r = -0,54**.

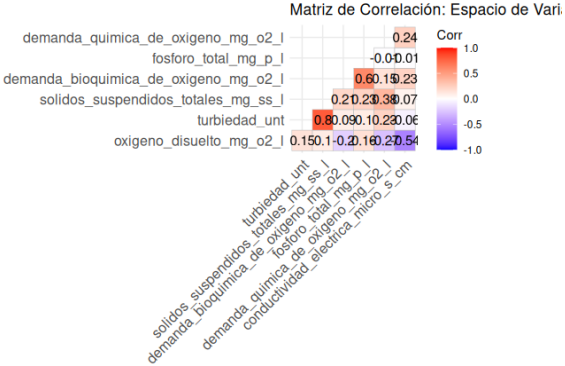

Varianza explicada

- Criterio de Kaiser: **3 componentes**.
- Dim 1: **31,57 %**.
- Dim 2: **25,43 %**.
- Dim 3: **20,15 %**.
- Acumulado: **77,15 %**.
- Plano 1-2: **57,00 %**.

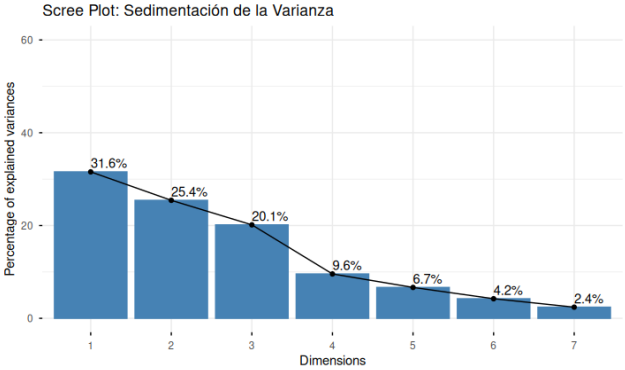

Interpretación de los ejes

- **Dim 1:** dominada por sólidos suspendidos, turbiedad, DBO, DQO y fósforo total.
- Interpretación: **gradiente de carga contaminante, orgánica y particulada**.
- **Dim 2:** dominada por oxígeno disuelto y conductividad eléctrica en sentidos opuestos.
- Interpretación: **contraste entre oxigenación e influencia iónica/conductiva**.

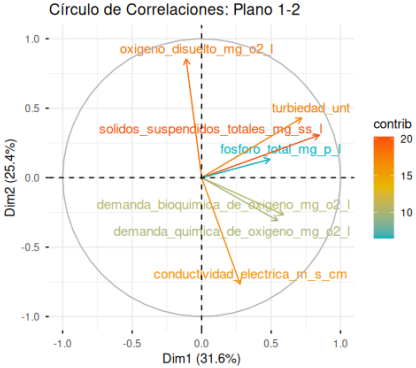

Nube de individuos

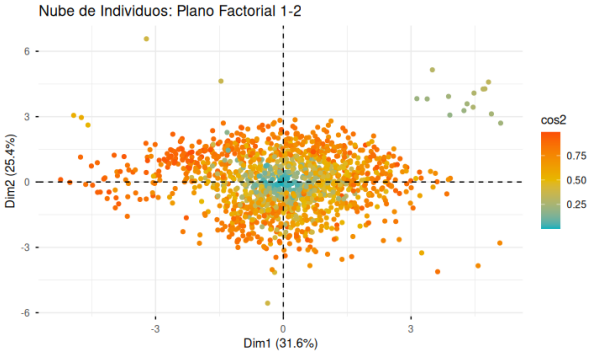

- Cada punto representa una observación espacio-temporal.
- Puntos cercanos al origen: perfiles más promedio.
- Puntos alejados: perfiles físico-químicos diferenciados.
- El color por coseno cuadrado indica qué tan bien queda representado el individuo en el plano 1-2.

Biplot y atípicos

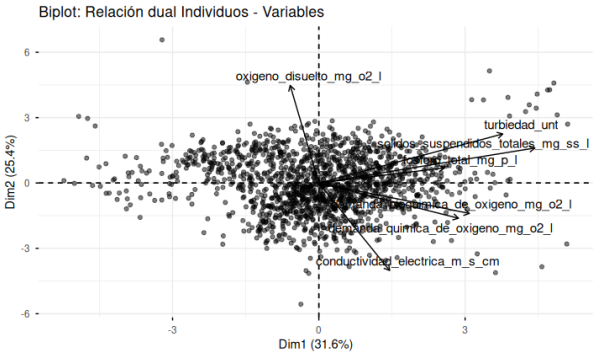

- El biplot integra individuos y variables.
- Puntos alejados del origen tienen perfiles diferenciados.
- Posibles atípicos factoriales:
  - 1993_JUANCHITO.
  - 2010_MEDIACANOA.
  - 2010_PASO DEL COMERCIO.
  - 2010_PUERTO ISAACS.
  - 2010_JUANCHITO.

No se eliminan automáticamente: pueden ser eventos ambientales reales.

Contribuciones y cosenos

Dim 1: carga contaminante

- Sólidos suspendidos: **32,36 %**.
- Turbiedad: **23,45 %**.
- DBO: **15,71 %**.

Dim 2: oxigenación/conductividad

- Oxígeno disuelto: **41,02 %**.
- Conductividad eléctrica: **32,98 %**.

Lectura: los cosenos cuadrados confirman que Dim 1 y Dim 2 representan fenómenos ambientales distintos y complementarios.

Índice parcial

- Sí es posible construir un índice, pero como **índice parcial de carga contaminante/particulada**.
- No debe interpretarse como índice global de calidad del agua.
- PC1 explica **31,57 %**; PC2 conserva información relevante sobre oxígeno disuelto y conductividad.

$$\text{Indice_PC1_0_100} = 100 \times \frac{PC1 - \text{mín}(PC1)}{\text{máx}(PC1) - \text{mín}(PC1)}$$

Mayores valores: 2010_LA VICTORIA, 1994_PASO DEL COMERCIO, 2010_ANACARO, 2010_MEDIACANOA y 2010_PASO DEL COMERCIO.
Mayores promedios por estación: ANACARO, PUENTE LA VIRGINIA, LA VICTORIA, VIJES y PUENTE GUAYABAL.

Conclusiones

1. El ACP resumió siete variables físico-químicas en tres componentes que explican **77,15 %**.
2. La Dim 1 representa carga contaminante y particulada.
3. La Dim 2 complementa la lectura mediante oxígeno disuelto y conductividad eléctrica.
4. Se identificaron observaciones extremas potencialmente relevantes.
5. El índice construido es útil para ordenar observaciones y estaciones, pero es **parcial**.

Mensaje final: la calidad del agua del Río Cauca debe leerse conjuntamente desde carga contaminante y condiciones de oxigenación/conductividad.

Preguntas probables

¿Por qué log1p? Por asimetría positiva severa y valores extremos.

¿Por qué estandarizar? Porque las variables estaban en unidades distintas.

¿Por qué tres componentes? Porque tres valores propios fueron mayores que 1 y explicaron 77,15 %.

¿Por qué el índice no es global? Porque PC2 contiene información ambiental relevante no resumida por PC1.

¿Qué significa un atípico en ACP? Una observación alejada del centro factorial; no necesariamente un error.